

Autocodificadores

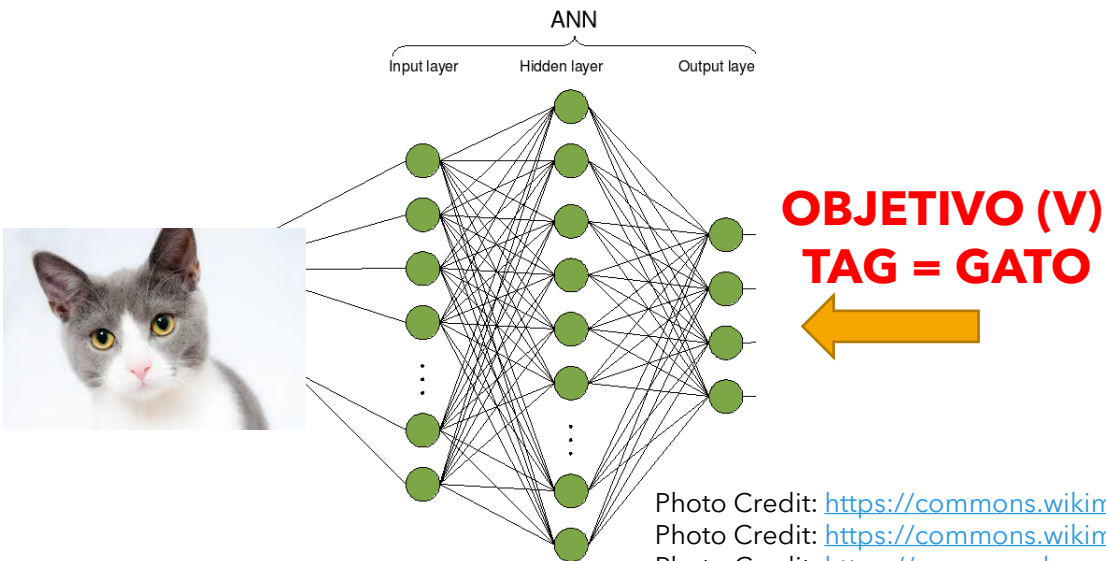
Inteligencia Artificial - Ejercicios
Avanzados

<https://datadosis.com>


Teoria: Autocodificadores

- Los codificadores automáticos son un tipo de redes neuronales artificiales que se utilizan para realizar una tarea de codificación de datos (aprendizaje de representación)
- Los codificadores automáticos usan los mismos datos de entrada para la entrada y la salida, Suena loco, ¿verdad?

APRENDIZAJE SUPERVISADO TRADICIONAL



APRENDIZAJE NO-SUPERVISADO POR AUTOCODIFICADOR



Capa del Código

- Los codificadores automáticos funcionan añadiendo un cuello de botella en la red.
- Este cuello de botella obliga a la red a crear una versión comprimida (codificada) de la entrada original
- Los codificadores automáticos funcionan bien si existen correlaciones entre los datos de entrada (funciona mal si todos los datos de entrada son independientes)
- referencia: "Introducción a los codificadores automáticos por Jeremy Jordan"

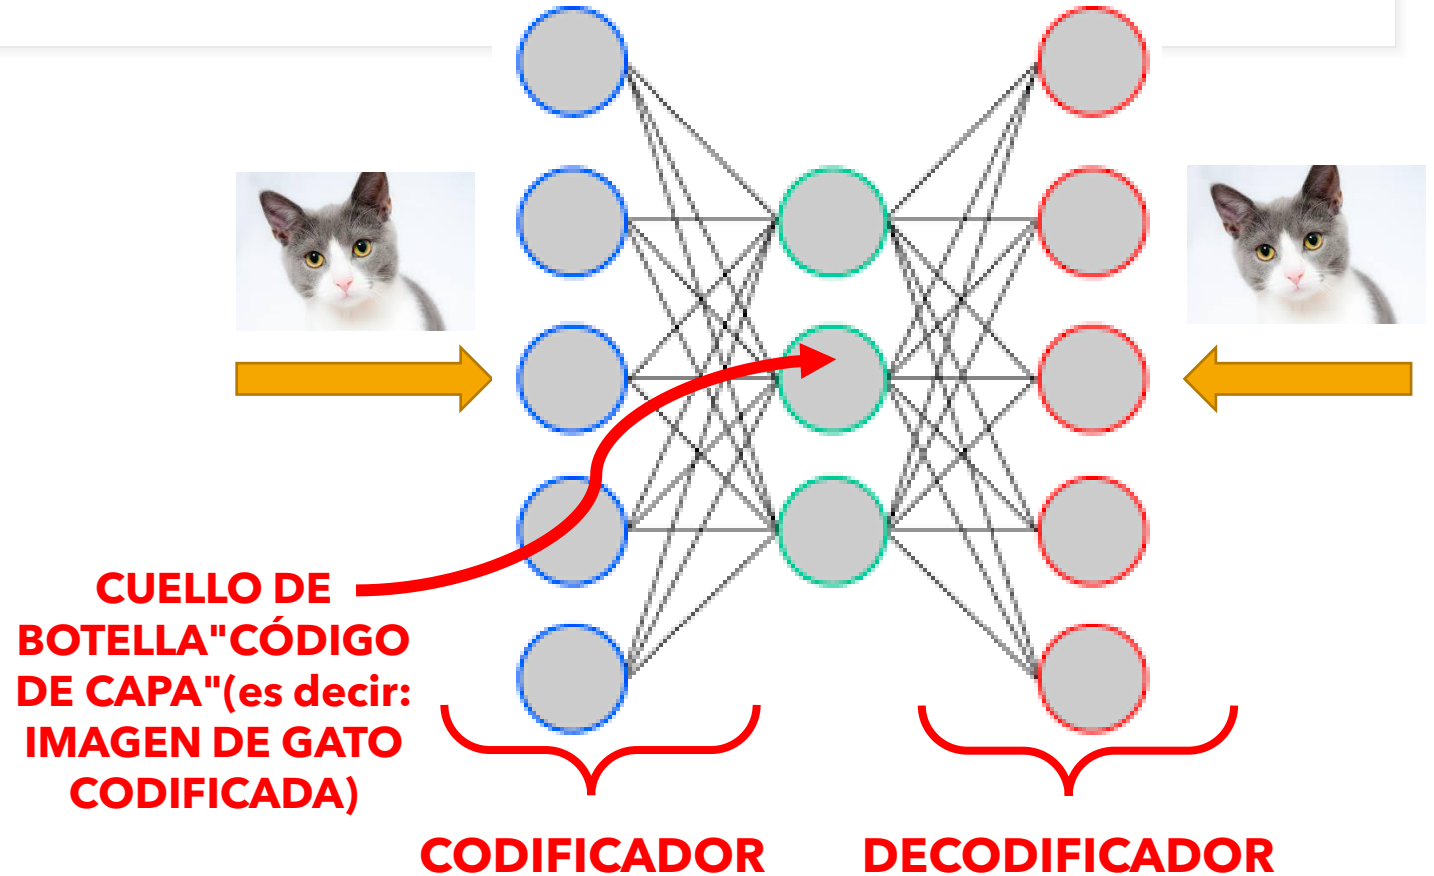


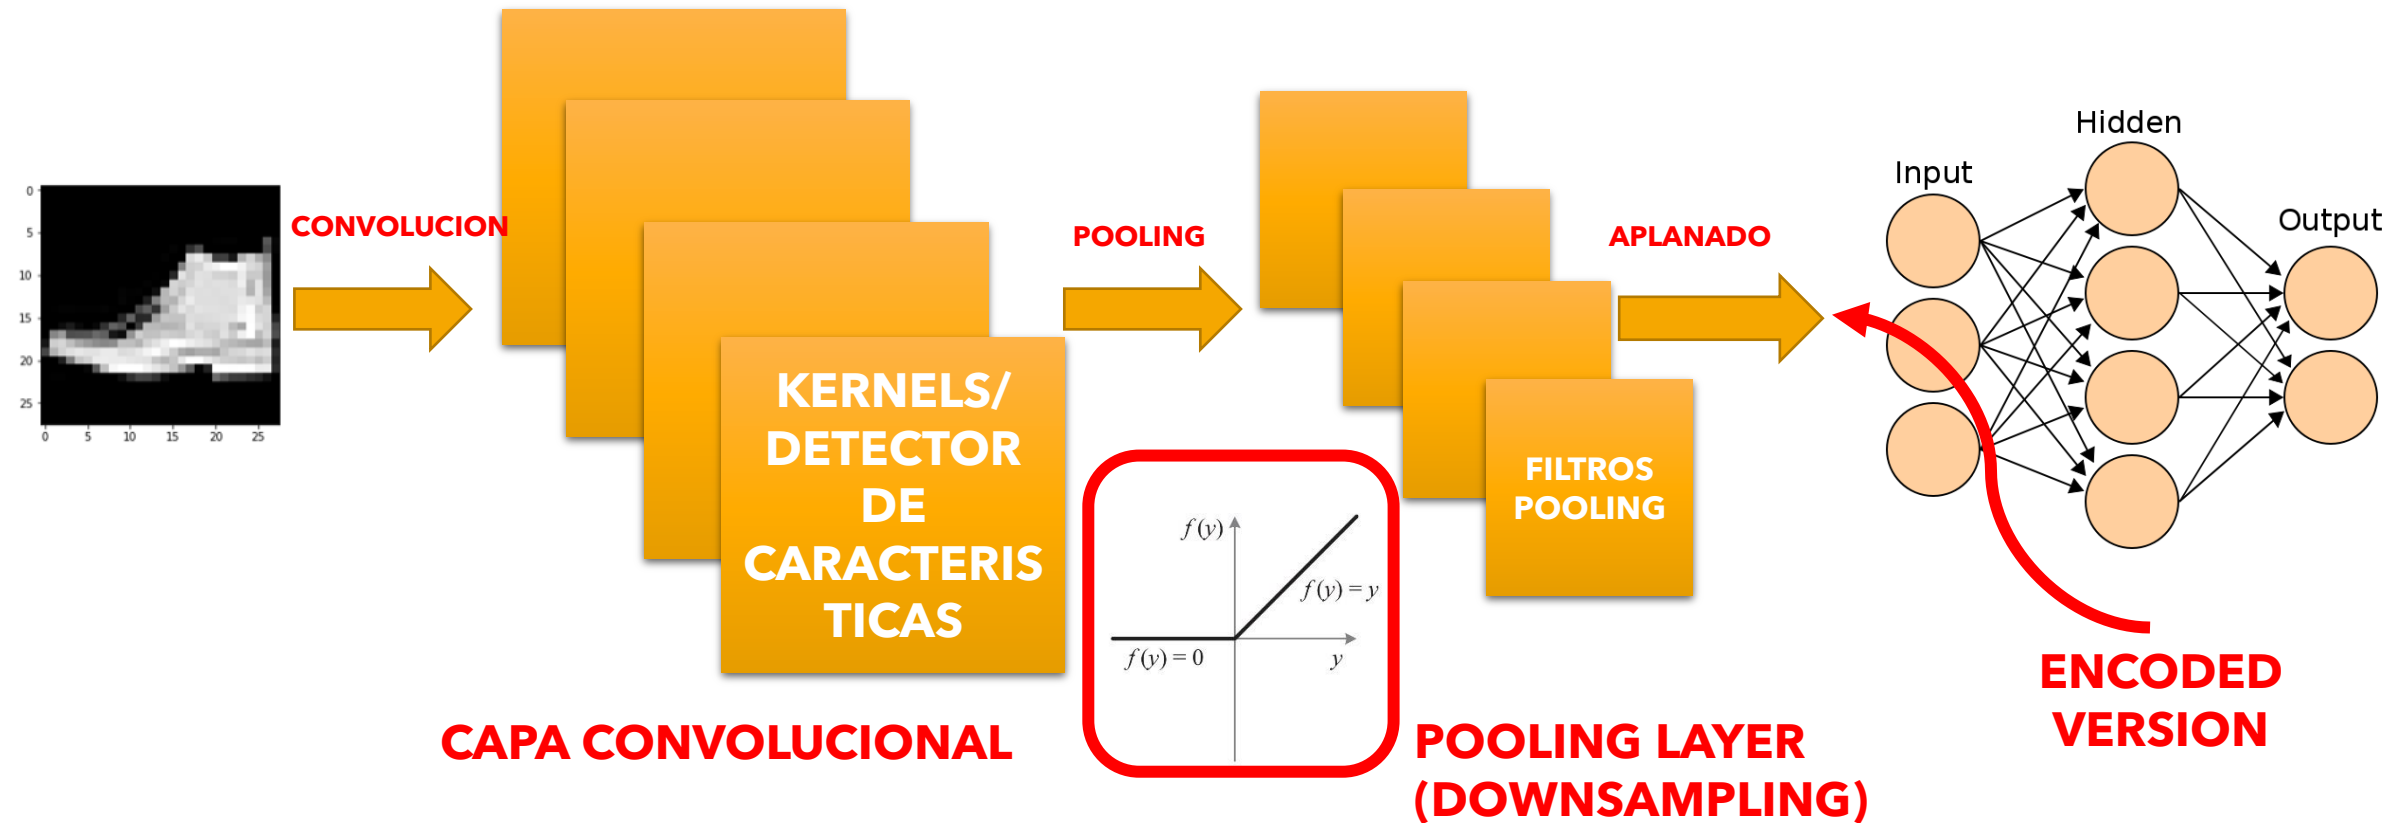
Photo Credit: https://commons.wikimedia.org/wiki/File:Autoencoder_structure.png

Photo Credit: https://commons.wikimedia.org/wiki/File:Artificial_neural_network_image_recognition.png

Photo Credit: <https://www.pexels.com/photo/grey-and-white-short-fur-cat-104827/>

Ya hemos codificado imagenes en el pasado

- Las RN Convolucionales realizan la codificación tomando los detectores de características y convirtiéndolos en una salida compacta unidimensional (que se alimenta a la red Dense totalmente conectada).



Matematicas de un Autocodificador

CODIFICADOR:

$$h(x) = \text{sigmoid}(W * x + b)$$


DECODIFICADOR:

$$\hat{x} = \text{sigmoid}(W^* * h(x) + c)$$

PESOS ATAJADOS:


Los pesos de la entrada a la capa oculta serán iguales a los pesos de la capa oculta a la salida

$$W^* = W^T$$



Reconstrucción del Error

- El objetivo de los codificadores automáticos es minimizar el error de reconstrucción que es la diferencia entre la entrada X y la salida de la red \hat{X}
- La reducción de la dimensionalidad de los codificadores automáticos (espacio latente) es bastante similar a la del PCA (Análisis de Componentes Principales) si se utilizan funciones de activación lineal



Dilema de Compensacion

- ¡El entrenamiento de los codificadores automáticos es bastante complicado!
- Queremos que nuestros codificadores automáticos entrenados lo sean:
 - capaces de reconstruir la entrada, por lo que la función de pérdida se formula de la siguiente manera $L(x, \hat{x})$
 - Evitar la sobrecarga y la memorización de los datos de entrenamiento
- Así que la función de pérdida se formula de la siguiente manera:

$$\textbf{Loss Function} = L(x, \hat{x}) + \textbf{Regularization Term}$$

**PARA PERMITIR LA
RECONSTRUCCIÓN
DE LA ENTRADA**

Photo Credit: https://commons.wikimedia.org/wiki/File:Autoencoder_structure.png

Photo Credit: https://commons.wikimedia.org/wiki/File:Artificial_neural_network_image_recognition.png

Photo Credit: <https://www.pexels.com/photo/grey-and-white-short-fur-cat-104827/>

**PARA EVITAR LA
SOBRECARGA Y LA
MEMORIZACIÓN DE
DATOS(MEJORAR LA
GENERALIZACIÓN)**

Autocodificadores vs PCA



EJEMPLO DE ANÁLISIS DE COMPONENTES PRINCIPALES

- La reducción de la dimensionalidad de los codificadores automáticos es bastante similar a la del PCA (Análisis de Componentes Principales) si se utilizan funciones de activación lineal

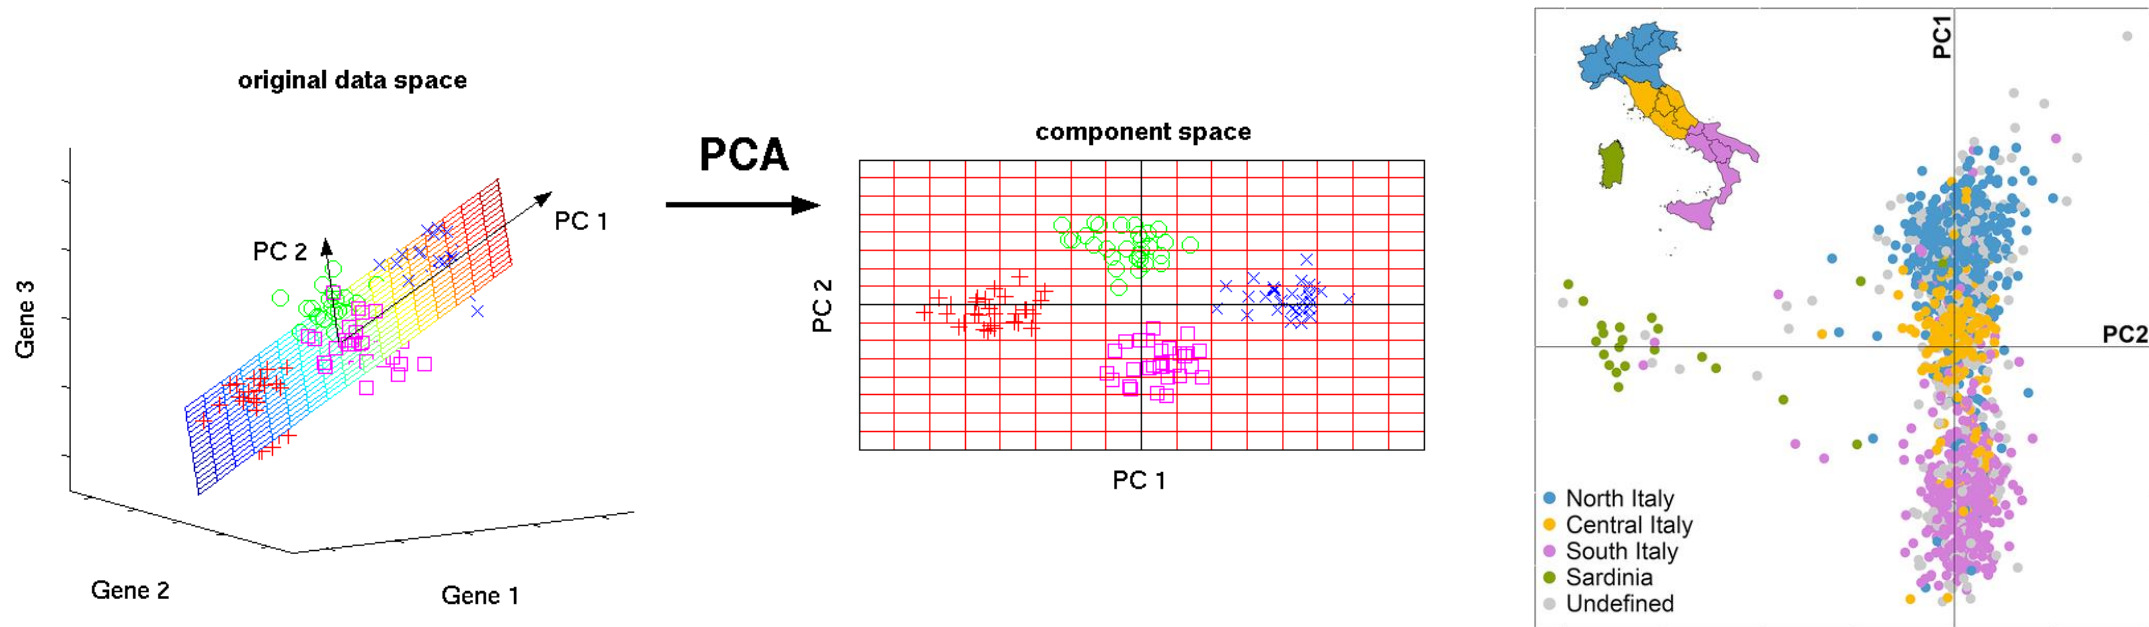



Photo Credit: https://commons.wikimedia.org/wiki/File:Principal_Component_Analysis_of_the_Italian_population.png


Photo Credit: <http://phdthesis-bioinformatics-maxplanckinstitute-molecularplantphys.matthias-scholz.de/>

EJEMPLO DE ANÁLISIS DE COMPONENTES PRINCIPALES

- La reducción de la dimensionalidad de los codificadores automáticos es bastante similar a la del PCA (Análisis de Componentes Principales) si se utilizan funciones de activación lineal



Aplicaciones de Autocodificadores



Aplicación #1: Reducción de Ruido con Autocodificadores

- Una aplicación muy utilizada de los codificadores automáticos es la de hacer des-ruidos.
- En lugar de alimentar exactamente los mismos datos que la entrada y la salida
- Alimentaremos una imagen ruidosa y luego fijaremos el objetivo para que sea la imagen original

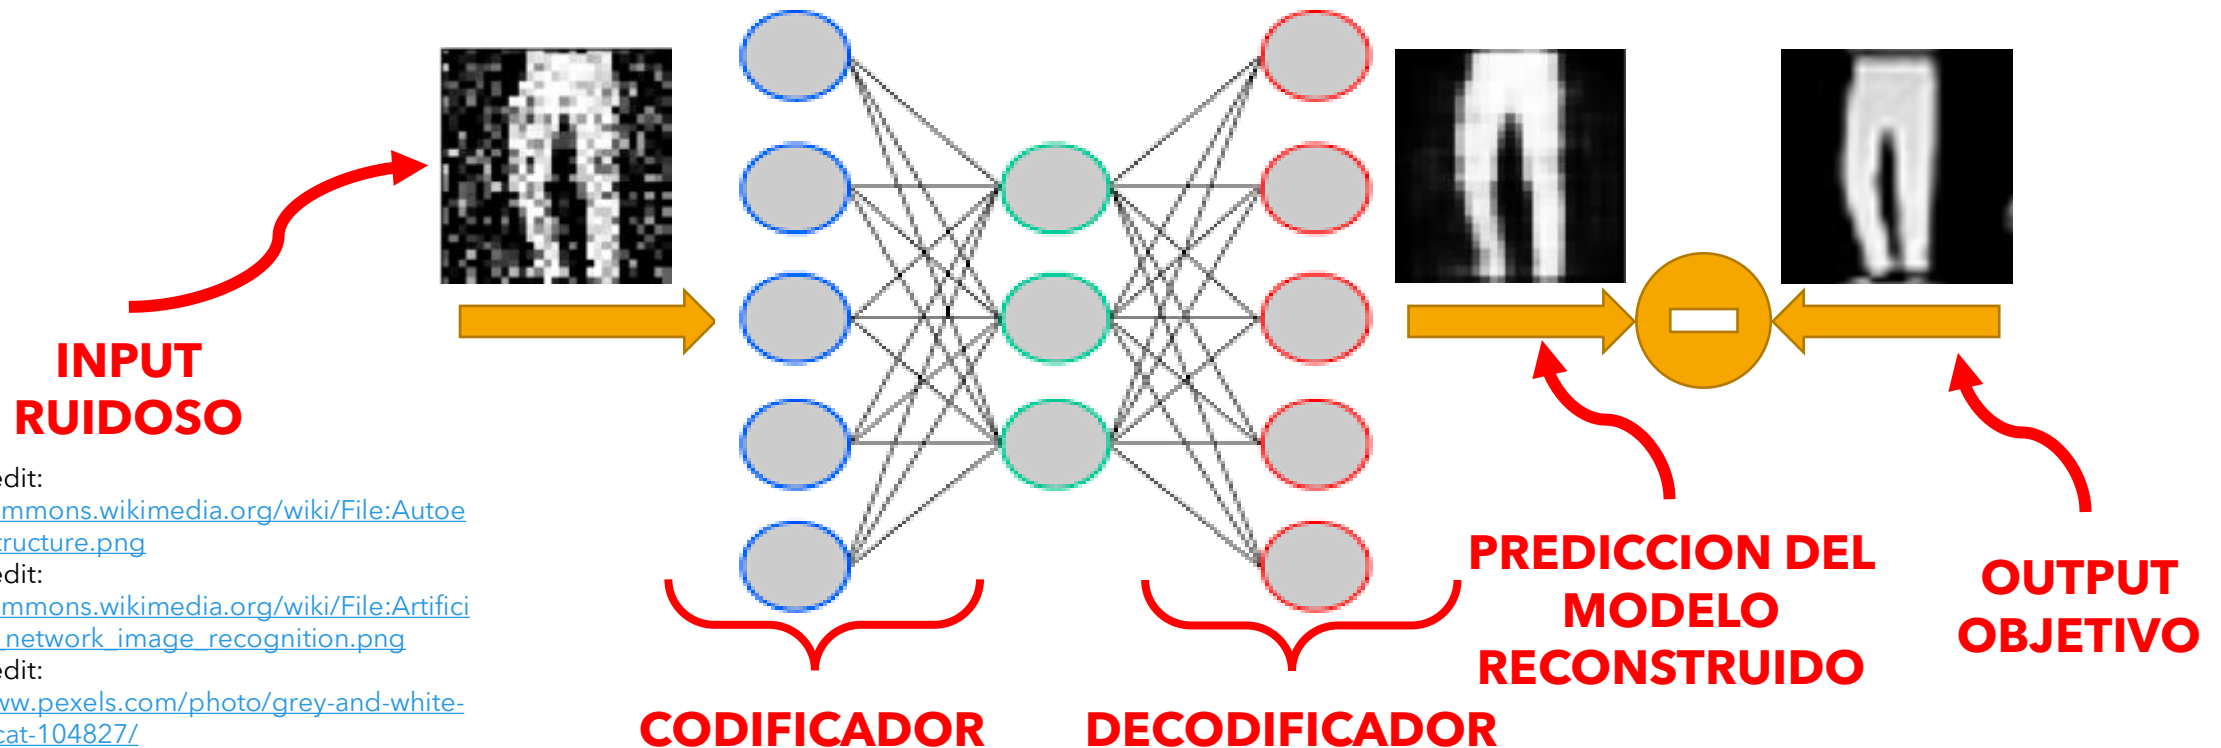

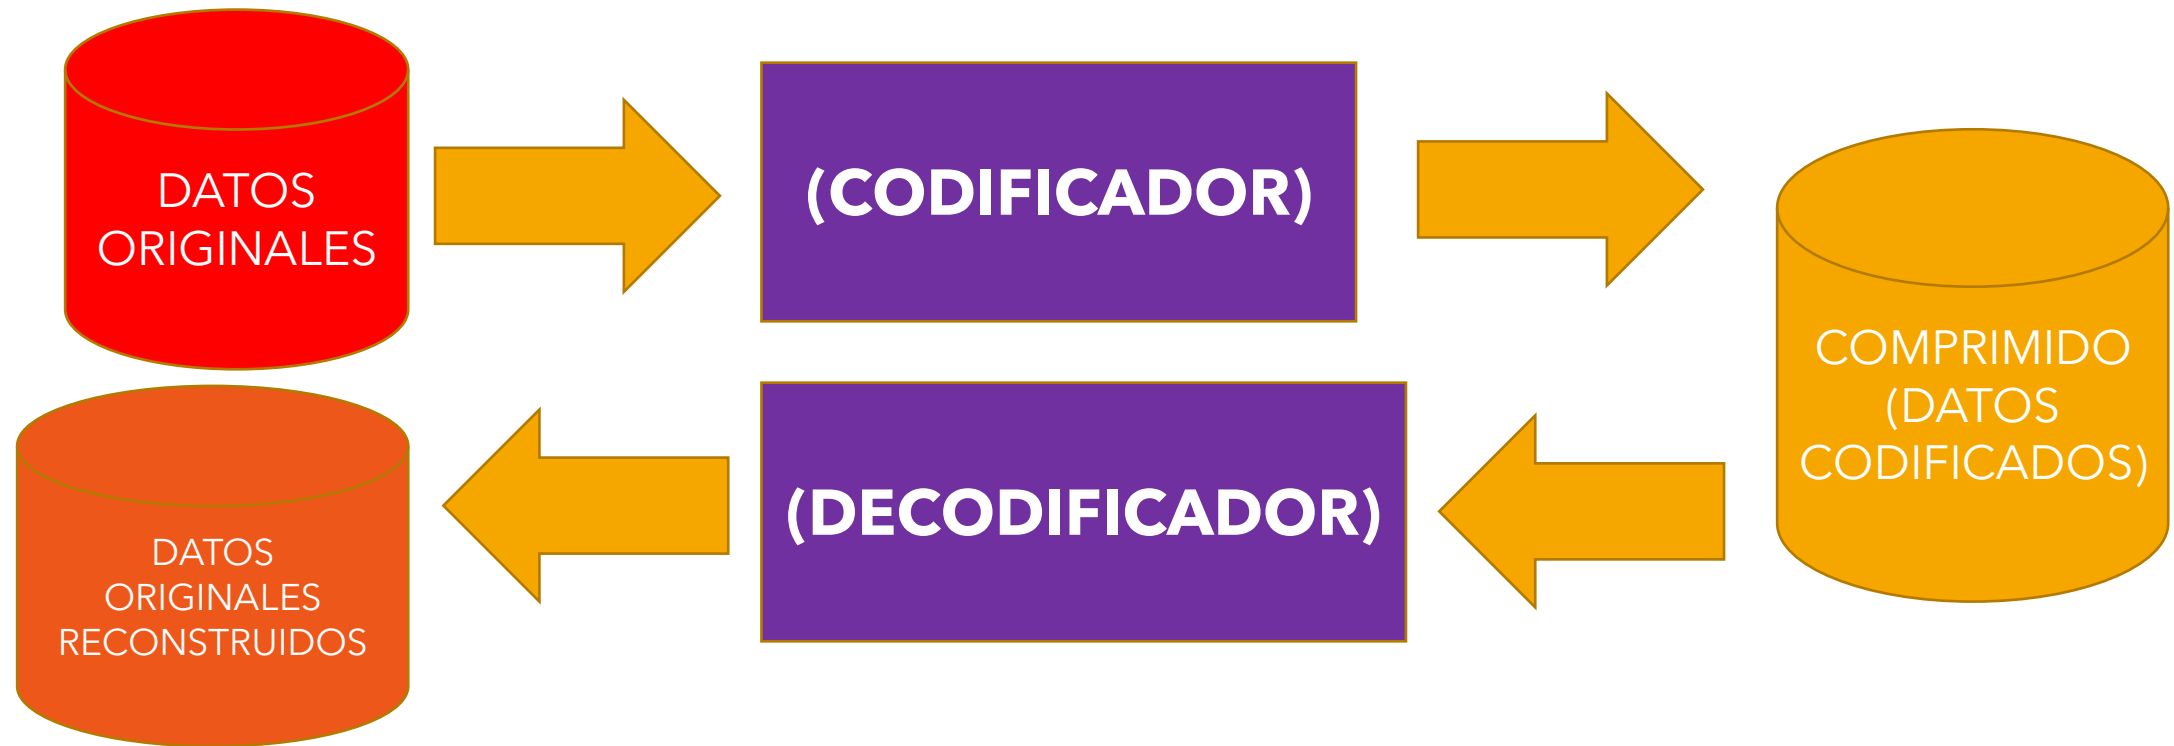


Photo Credit:
https://commons.wikimedia.org/wiki/File:Autoencoder_structure.png
Photo Credit:
https://commons.wikimedia.org/wiki/File:Artificial_neural_network_image_recognition.png
Photo Credit:
<https://www.pexels.com/photo/grey-and-white-short-fur-cat-104827/>


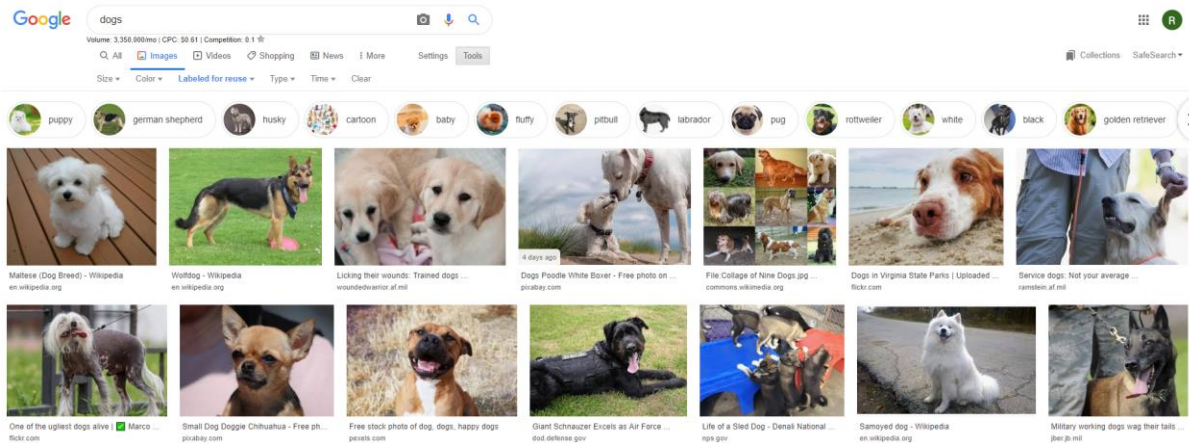
Aplicación #1: Reducción de Ruido con Autocodificadores



Aplicacion #2: Compresion de Imagen



Aplicacion #3: Busqueda de Imagen



Aplicacion #4: Deteccion de Anomalia


- Los codificadores automáticos se utilizan para la detección de anomalías, como la detección de fraudes con tarjetas de crédito.
- Entrenaremos a los codificadores automáticos en transacciones apropiadas (no fraudulentas) SOLAMENTE
- De esta manera, la red es ahora capaz de reconstruir la entrada con una buena pérdida de reconstrucción.
- Si se alimenta una transacción fraudulenta (anomalía), la pérdida de reconstrucción será grande, ahora se puede establecer un umbral para realizar la detección de la anomalía.

Autocodificadores Variacionales (VARS)



AUTOCODIFICADORES VARIACIONALES (VARS)


- Un problema importante de los codificadores automáticos normales es que el espacio latente en el que se convierten las entradas es discreto (no continuo) y no permite una interpolación fácil.
- La parte generativa del codificador automático funciona escogiendo aleatoriamente muestras del espacio latente, lo que supone un reto si es discontinuo o tiene lagunas.
- Los Autocodificadores Variacionales están aquí para resolver este problema



AUTOCODIFICADORES VARIACIONALES (VARS)

- Los codificadores automáticos variables tienen un espacio latente continuo por defecto que los hace súper poderosos en la generación de nuevas imágenes.
- En los VAR, el codificador no genera un vector de tamaño n , sino que genera dos vectores como sigue:
 - Vector medio μ
 - Desviaciones estándar σ
- Entonces el decodificador puede empezar a tomar muestras de esta distribución
- Gran recurso de Irhum Shafkat: <https://towardsdatascience.com/intuitively-understanding-variational-autoencoders-1bfe67eb5daf>
- Si quieres aplicar codificadores automáticos variados para añadir gafas a una cara, por ejemplo, puedes hacerlo mediante: (1) codificando una cara con gafas, y (2) codificando una cara sin gafas y (3) simplemente restando las dos, se obtiene una versión codificada de las gafas solamente, (4) Luego se pueden añadir estas gafas codificadas a cualquier cara más tarde

AUTOCODIFICADORES VARIACIONALES (VARS)





REVISIÓN DE LAS DIMENSIONES RNC

- El tamaño espacial del volumen de salida es una función de:
 - Tamaño del volumen de la imagen de entrada (W)
 - Tamaño del campo receptor de la capa convolucional (F)
 - Stride (S)
 - Cantidad de relleno cero (P)
- La ecuación es la siguiente:

$$O = (W - F + 2P) / S + 1.$$

- Por ejemplo:
 - Con stride = 1, entrada de 7x7 y filtro de 3x3, pad = 0, la salida será = 5x5.
 - Con stride = 2, entrada 7x7 y filtro 3x3, pad = 0, la salida será = 3x3.
- La fórmula utilizada para medir el valor del relleno para conseguir que el tamaño espacial del volumen de entrada y de salida sea el mismo con el stride 1:


$$P = (F - 1) / 2$$



¿CUÁL ES EL SIGNIFICADO DEL PADDING / Relleno = 'MISMO'?

- El mismo relleno significa que el tamaño del mapa de características de salida será similar al de los mapas de características de entrada (asumiendo que la zancada=1).
- Por ejemplo, si la imagen de entrada es de 28 x 28, entonces el mapa de salida será también de 28 x 28.


$$P = (F-1)/2 = (3-1)/2 = 1$$



RELLENO = "MISMO" EJEMPLO

- $$P = \frac{F-1}{2} = \frac{5-1}{2} = 2$$

$F = 5$



$W = 10$